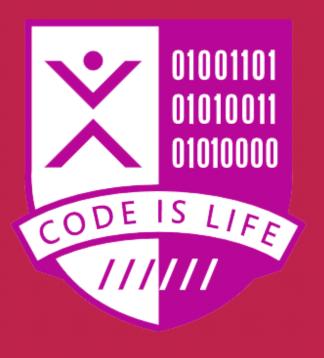
MSP evangelism 2016 장고: 분노의 개발자

사전과제 4 beautifulsoup

Team. 방울뱀







BeautifulSoup4를 이용해서 HTML을 읽어보자.





Requests로 response를 갖고오자!

```
import requests
>>> URL = 'http://www.tistory.com'
   response = requests.get(URL)
   response.status code
>>> response.text
'<!DOCTYPE html>\m<html lang="ko">\m<head>\mn\mt<meta charset="utf-8">\mn\mt<meta property="og:url" content=
nt="TISTORY">\m\t<meta property="og:title" content="TISTORY">\m\t<meta property="og:description" content
mage" content="https://t1.daumcdn.net/cssis/icon/557567EA016E200001">\n\text{https://t1.daumcdn.net/cssis/icon/557567EA016E200001">\n\text{https://t1.daumcdn.net/cssis/icon/557567EA016E200001">\n\text{https://t1.daumcdn.net/cssis/icon/557567EA016E200001">\n\text{https://t1.daumcdn.net/cssis/icon/557567EA016E200001">\n\text{https://t1.daumcdn.net/cssis/icon/557567EA016E200001"
op/favicon.ico">\n\taut<link rel="stylesheet" href="//s1.daumcdn.net/svc/attach/U0301/cssjs/tistory-web-top
uch-icon" href="http://i1.daumcdn.net/thumb/C180x180/?fname=http://cfile5.uf.tistory.com/image/241F093D
href="http://il.daumcdn.net/thumb/C76x76/?fname=http://cfile5.uf.tistory.com/image/214AF9425701E76D0ACB
://il.daumcdn.net/thumb/C120x120/?fname=http://cfile5.uf.tistory.com/image/241F093D5701E7380371B5">\m
umcdn.net/thumb/C152x152/?fname=http://cfile5.uf.tistorv.com/image/241F093D5701E7380371B5">\m\m<link_re
ory-web-top/1479281235/static/css/pc/T.p.top.home.css">\m\m<!--[if It IE 9]>\m<script type="text/iavasc
///"Il.O.min.is"×/script>\n<![endif]-->\n<!--[if gte IE 9]×!-->\n<script type="text/iavascript" src="
×/script>\n<!-≺![endif]-->\n<script type="text/javascript" src="//s1.daumcdn.net/svc/original/U03/css
ype="text/javascript" src="//s1.daumcdn.net/svc/original/U03/cssis/userAgent/userAgent-1.0.14.min.is">
daumGnb">메뉴 바로가기</a>₩n₩t₩t<a href="#daumBody">본문 바로가기</a>₩n₩t</div>₩n₩t<div id="daumWrap">#
#t₩t₩t₩t<a href="/" id="daumServiceLogo" class="#logo"≫span class="ir_wa">TISTORY</span≫/a>₩n₩t₩t₩t</
an×/a×/li>₩n\t\t\t\t\t\t\t\lankarti×a href="/category" class="link_gnb_link_gnb2 #best"×span class="ir_wa">주
<a href="/community" class="link_gnb link_gnb3 community_sub #community"×span class="ir_wa">커뮤니티<
nk_gnb link_gnb4 #skin"×span class="ir_wa">스킨</span×/a×/li>\n\\t\t\t\t\t\t\t\i>a href="http://award.b
target="_blank"×span class="ir_wa">우수블로그</span×/a×/li>\m
   시작하시려면. 초대장 받기</a>₩n₩t₩tWt</div>₩n₩t₩t</div>₩n₩t₩t<hr class="hide">₩n₩t₩t<div id="daumCon
  \t\t\t\t\t\t\t\t\t\t\t\t<a href="http://notice.tistory.com/2355" class="link_notice">개인정보처리방침 변경
  |ity=#login_section">\n\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\ton=id="loginLayerOpenButton" type="button" class=
       t\t\t\t\t\t\t\t\topiavid="loginLaver" class="laver login" stvle="displav: none">\n\topia\t\t\t\t\t\t\t\t\topia
```





지금 받아 오긴 했는데, HTML은 text로 되어있다. 이걸 하나하나 어떻게 찿지…

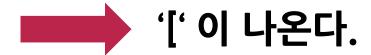




Text와 자료구조의 차이점

보이는 건 동일해 보일 지 몰라도, 컴퓨터가 이해한 방식이 다르다.

• String '[1,2,3]' 에서 첫 번째 원소를 꺼내 보자.



• 이제, 컴퓨터가 이해하도록 eval('[1,2,3]')을 한 뒤에 첫번째 원소를 꺼내 보자.







Recall. DOM Tree

Text를 분석해서 DOM Tree를 컴퓨터가 이해하도록 해보자.

사실, 이미 누가 다 짜놨다. 그게 바로 BeautifulSoup





Tips & Tricks





- soup = BeautifulSoup(text, 'html.parser')
 - text를 tree로 만들자.
- Tree의 자식도 Tree! (Recall. Tree)
 - 그러므로 soup에서 찾은 결과 역시 soup과 동일한 method들을 사용할 수 있고, 동일한 변수를 갖고 있다.
- soup.find('tag_name'), soup.tag_name
 - 맨 처음 해당 tag를 갖는 tag를 반환한다.
- soup.find('tag name', {'attribute name': 'attribute value', ... })
 - 특정 Attribute를 갖는 tag를 갖고 온다.
- soup.find(['a', 'p'])
 - 여러 tag를 동시에 찾을 수도 있다.

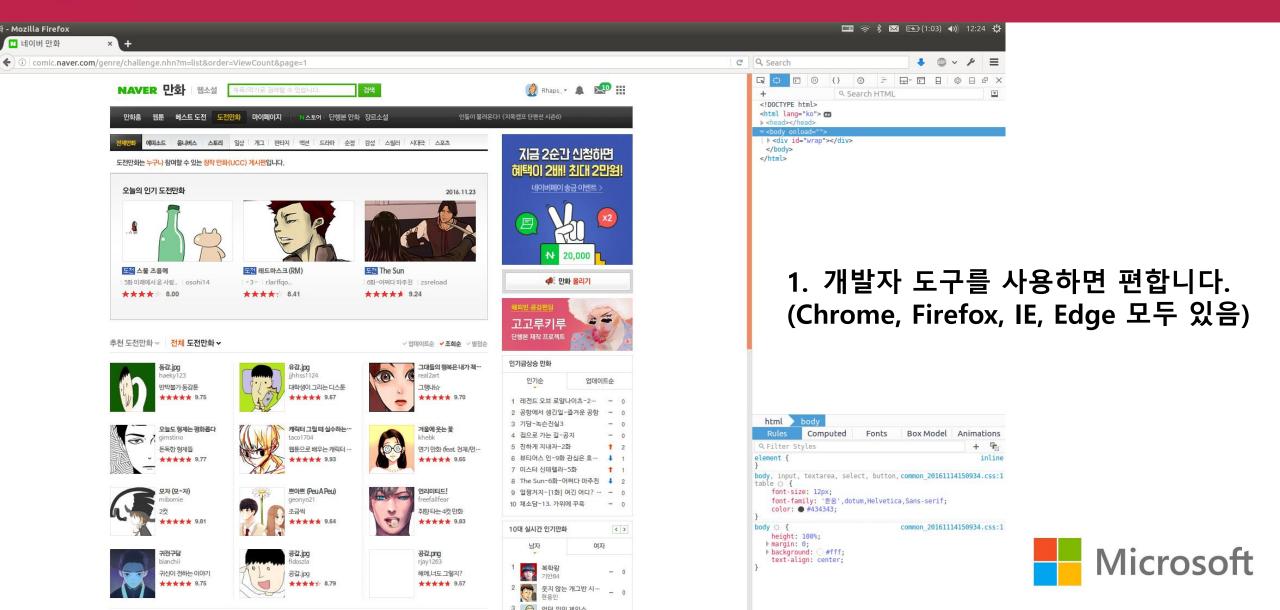




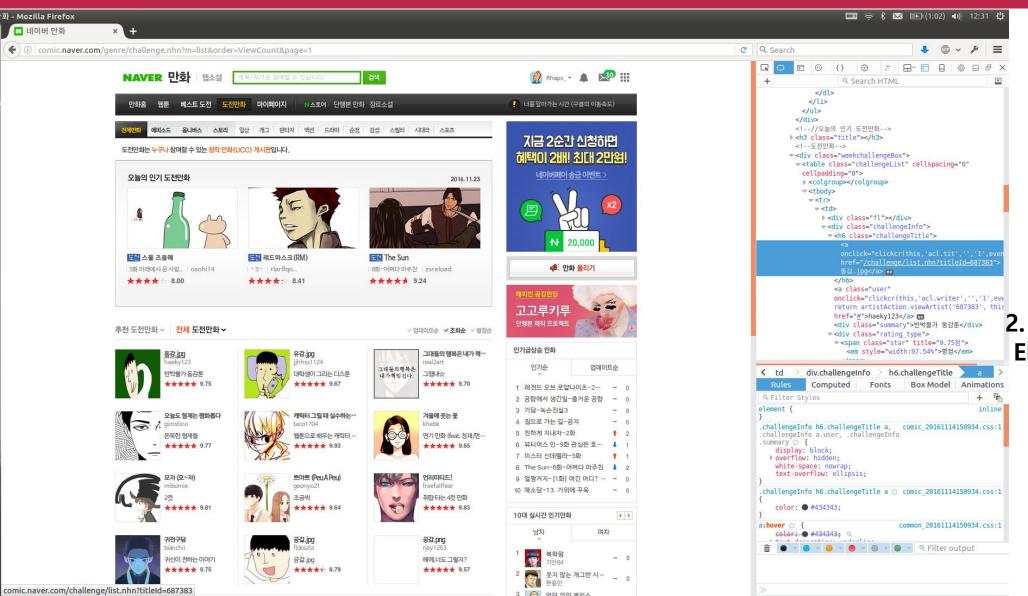
- soup.find_all()
 - 아까와 하는 건 똑같지만, 모든 tag를 list로 반환한다.
- soup.get_text(), soup.text
 - Value를 리턴한다. (Recall. HTML Variables)
- soup['attribute']
 - Attribute를 리턴한다. (Recall. HTML Variables)
- soup.parent, soup.child, soup.siblings
 - 각각 부모, 자식, 같은 부모를 갖는 자식들을 return한다. (Recall. Tree)
- soup.extract(), soup.append('Some text')
 - 해당 object를 빼거나 해당 text를 해당 object의 value append할 수 있다.







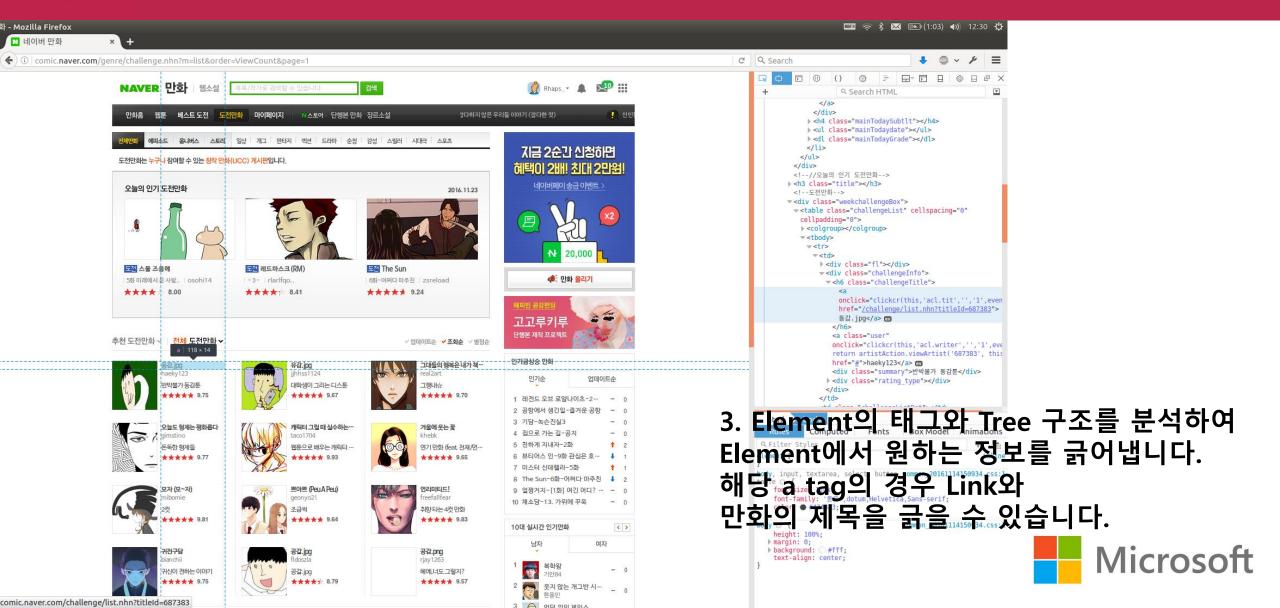




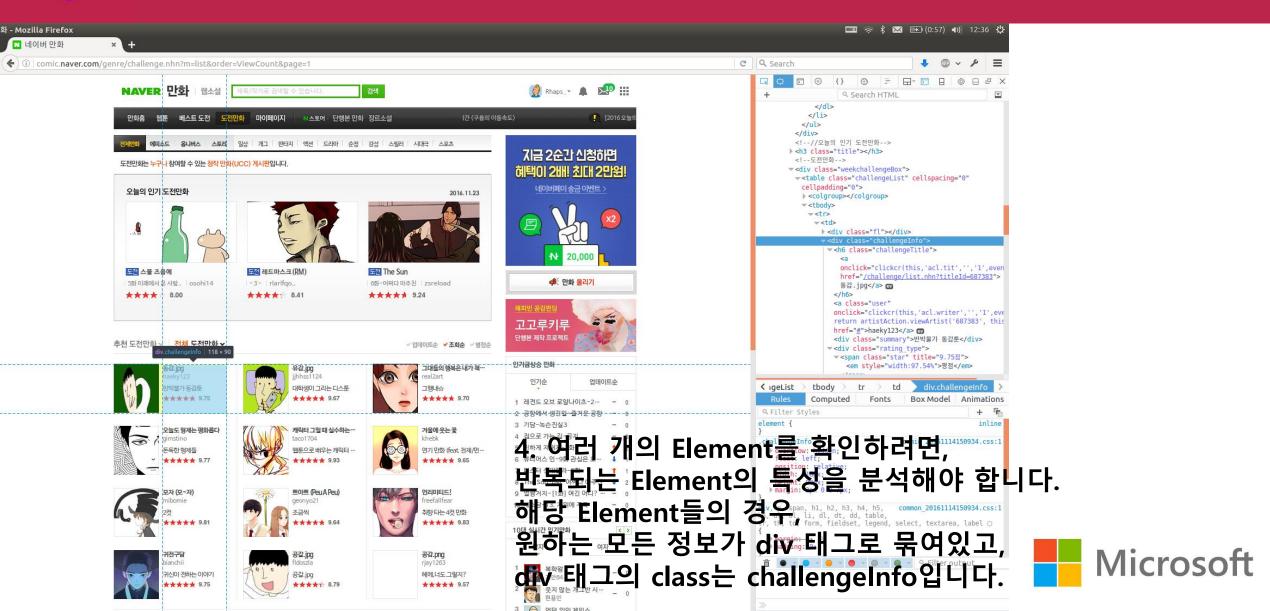
2. 해당 Page에서 원하는 Element를 고릅니다.











```
import requests
from bs4 import BeautifulSoup
for idx in range(1, 10):
  url = 'http://comic.naver.com/genre/challenge.nhn?m=list&order=ViewCount&page=' + str(idx)
  html = requests.get(url)
  soup = BeautifulSoup(html.text, 'html.parser')
  divs = soup.findAll('div', 'challengeInfo')
                                                       예제를 실행하여,
  for div in divs:
                                                       네이버 만화 페이지 메인에 있는
    title = div.find('h6', 'challengeTitle')
                                                       전체 도전만화의 제목들을 가져올 수 있다.
    url = title.find('a')['href']
    title = title.find('a').string
    rating = div.find('strong').string
    if float(rating) > 9.5:
       print('%s[%s] (%s)' % (title, rating, 'http://comic.naver.com' + url))
```